

A decorative graphic on the left side of the slide consisting of two overlapping parallelograms. The front one is blue and the back one is light green. Both are tilted at an angle.

Construisez un modèle de scoring

Projet 4 - Julien Agneray



Sommaire

1. Introduction et problématique métier
2. Exploration et préparation des données
3. Feature engineering
4. Modélisation et optimisation
5. Interprétabilité et adaptation au contexte métier
6. Conclusion et perspectives
7. Questions



Introduction et problématique métier

Développement d'un Modèle de Scoring Crédit

Contexte :

- La société financière “Prêt à dépenser” propose des crédits à la consommation aux clients avec peu ou pas d'historique de prêt.

Objectifs :

- Créer un outil de scoring crédit pour prédire la probabilité de remboursement d'un prêt.
- Classer les demandes en deux catégories : Crédit accordé ou Crédit refusé.

Méthodologie :

- Interprétabilité : Modèle facilement compréhensible par les chargés de relation client.
- Données : Historique de prêts, informations financières, données comportementales.

Conclusion :

- Un modèle performant et interprétable pour des décisions de crédit éclairées.



Exploration et préparation des données

Le jeu de données

Fichiers Principaux :

- `application_train.csv` et `application_test.csv` : Contiennent les informations sur les clients et leurs demandes de prêt, y compris l'âge, le revenu et des informations financières détaillées.

Fichier de Description :

- `HomeCredit_columns_description.csv` : Fournit une description complète de toutes les variables présentes dans les jeux de données.


Fichiers Complémentaires :

- `bureau.csv` et `bureau_balance.csv` : Informations sur les crédits précédents des clients auprès d'autres institutions financières.
- `credit_card_balance.csv` : Historique des soldes de cartes de crédit des clients.
- `installments_payments.csv` : Détails des versements effectués par les clients pour rembourser.
- `POS_CASH_balance.csv` : Données des crédits contractés pour des achats de biens.
- `previous_application.csv` : Informations sur les demandes de crédit précédentes faites par les clients.

Exploration et préparation des données

Exploration


La variable cible est 'TARGET' et elle est à 0 pour un prêt remboursé à temps ou à 1 quand le client a eu des difficultés de paiement. L'analyse montre un déséquilibre de classes.



Exploration et préparation des données

Exploration



J'ai identifié les variables catégorielles dans le jeu de données et appliqué un codage par étiquette pour celles ayant deux catégories uniques. Pour les variables comportant plus de deux catégories, j'ai utilisé un encodage one-hot.



Exploration et préparation des données

Exploration


J'ai détecté et traité les anomalies, notamment pour la variable `DAYS_EMPLOYED`, qui reflète le nombre de jours avant la demande pendant lesquels la personne a débuté son emploi actuel.



Exploration et préparation des données

Exploration


J'ai calculé le coefficient de corrélation de Pearson entre chaque variable et la cible.



Exploration et préparation des données

Exploration


Les jeunes demandeurs sont plus susceptibles de ne pas rembourser le prêt ! Le taux de non-remboursement est supérieur à 10 % pour les trois groupes d'âge les plus jeunes et inférieur à 5 % pour le groupe le plus âgé.



Exploration et préparation des données

Exploration

Les trois variables présentant les corrélations négatives les plus fortes avec la cible sont `EXT_SOURCE_1`, `EXT_SOURCE_2` et `EXT_SOURCE_3`. D'après la documentation, ces caractéristiques représentent un "score normalisé provenant d'une source de données externe".



Les trois caractéristiques `EXT_SOURCE` ont des corrélations négatives avec la cible, ce qui indique que plus la valeur de l'une de ces variables augmente, plus le client est susceptible de rembourser le prêt. Nous pouvons également constater que `DAYS_BIRTH` est fortement corrélé positivement avec `EXT_SOURCE_1`, ce qui suggère que l'âge du client est probablement un facteur pris en compte dans ce score externe.



Feature engineering

Dans cette étape, j'ai enrichi les données brutes en créant de nouvelles variables, ou features, qui capturent des informations plus pertinentes pour la prédiction du risque de crédit. Ces nouvelles caractéristiques permettent de mieux représenter la situation financière et familiale des clients, aidant ainsi le modèle à discriminer plus efficacement les profils à risque.

Exemples de Features Créées :

1. ``DAYS_EMPLOYED_PERC`` : Ratio entre le nombre de jours travaillés (``DAYS_EMPLOYED``) et l'âge du client (``DAYS_BIRTH``), indicateur potentiel de stabilité financière.
2. ``AVG_FAM_MEMBER_AGE`` : Moyenne de l'âge des membres de la famille, donnant une idée de la composition du ménage et de son impact potentiel sur le risque de défaut.
3. ``EXT_SOURCE_1_YEARS_BIRTH`` : Combinaison d'une source externe de score (``EXT_SOURCE_1``) avec l'âge du client (``YEARS_BIRTH``), pour une meilleure évaluation du profil de risque.



Modélisation et optimisation

Préparation du jeu de données

Pour garantir des données propres et utilisables dans les modèles, j'ai appliqué plusieurs étapes de traitement et de préparation :

1. **Suppression de la colonne d'identifiant** : La colonne `SK\_ID\_CURR`, qui est un identifiant unique, a été retirée car elle n'apporte aucune information pour la modélisation.
2. **Séparation Train/Test** : Les données sont divisées entre jeu d'entraînement (avec `TARGET`) et jeu de test (sans `TARGET`), pour garantir une évaluation fiable.
3. **Traitement des valeurs manquantes** : Nous avons remplacé les valeurs manquantes dans les colonnes numériques par la médiane et celles des colonnes catégorielles par la valeur la plus fréquente.
4. **Nettoyage des noms de colonnes** : Les noms de colonnes sont standardisés pour éviter les erreurs.
5. **Séparation des features et de la cible** : Les colonnes prédictives (features) sont séparées de la colonne cible (TARGET) afin de préparer les jeux de données X (caractéristiques) et y (cible) pour la modélisation.



Modélisation et optimisation

Fonction de Coût Personnalisée

Une fonction de coût sur-mesure a été mise en place pour adapter l'optimisation du modèle aux exigences métier de la société "Prêt à dépenser". Cette fonction prend en compte deux types d'erreurs :

- **Les faux négatifs (FN)** : Cas où un client à risque est classé comme non-risque. Cela entraîne un coût élevé pour la société (ex. : un client qui ne rembourse pas le prêt).
- **Les faux positifs (FP)** : Cas où un client non-risque est classé comme à risque. Le coût est moindre, mais cela peut représenter une opportunité manquée.


La fonction calcule un coût total basé sur un **ratio de 10 pour les faux négatifs et 1 pour les faux positifs**, ce qui permet de minimiser les erreurs ayant le plus d'impact financier.

Modélisation et optimisation

Fonction de Coût Personnalisée

Vrais négatif : Clients
à faible risque
correctement prédits

Faux négatif : Clients
à risque
incorrectement
prédits




Faux positif : Clients
à faible risque
incorrectement
prédits

Vrais positif : Clients
à risque
correctement prédits

Modélisation et optimisation Pipeline

Gestion du Déséquilibre des Classes

- **None** : Sans correction, le modèle a été testé avec les données déséquilibrées, majoritairement constituées de clients remboursant leur prêt. Cela permet d'évaluer les performances de base du modèle.
- **Undersampling** : La taille de la classe majoritaire a été réduite pour équilibrer les classes. Cette méthode améliore la détection des clients à risque et réduit les temps de calcul.





Modélisation et optimisation Pipeline


Remarque sur les autres techniques non utilisées :

Oversampling et class_weight : Bien que ces méthodes soient couramment utilisées pour gérer le déséquilibre des classes, elles ont été exclues ici. L'oversampling, qui duplique les instances de la classe minoritaire, aurait considérablement allongé les temps de calcul. Quant à l'ajustement des poids avec class_weight, il aurait également augmenté la complexité computationnelle, ce qui aurait ralenti le processus d'entraînement des modèles.


Conclusion :

Tous les modèles ont été testés avec les deux approches, None et Undersampling, pour évaluer l'impact de la gestion du déséquilibre des classes sur les performances. Ces stratégies m'a permis d'optimiser les performances tout en maîtrisant les temps de calcul.

Modélisation et optimisation Pipeline



Modélisation et optimisation Pipeline





Modélisation et optimisation Pipeline

Processus de Sélection :

J'ai comparé les modèles en fonction de ces différentes métriques, mais la décision finale s'est basée sur la minimisation du coût métier. Le modèle final a été choisi pour son efficacité à réduire ces coûts tout en offrant de bonnes performances globales.

Conclusion :


Le modèle sélectionné répond aux objectifs financiers de l'entreprise en optimisant la gestion des risques tout en garantissant une bonne généralisation des prédictions sur des données jamais vues. En prenant en compte à la fois les coûts métier et les performances globales, ce modèle permet de mieux anticiper les défaillances de paiement, tout en minimisant les erreurs coûteuses. Grâce à cette approche, la société "Prêt à dépenser" peut prendre des décisions de crédit plus éclairées et plus rentables.

Modélisation et optimisation

Recherche du seuil de décision optimal

Une fois le modèle final sélectionné, j'ai optimisé le seuil de décision pour maximiser l'efficacité du modèle sur le plan métier. Ce seuil contrôle la manière dont les probabilités de prédiction sont converties en décisions binaires (accorder ou refuser un prêt).

J'ai utilisé une validation croisée pour tester plusieurs seuils compris entre 0 et 1. Pour chaque seuil, j'ai calculé le coût métier moyen, en prenant en compte les faux positifs et les faux négatifs. Mon objectif était de trouver le seuil qui minimisait ce coût.



Le meilleur seuil trouvé était de **0.55**, ce qui représente un équilibre entre la minimisation des erreurs coûteuses tout en conservant une bonne performance globale du modèle. Cela a permis d'ajuster le modèle pour qu'il soit le plus efficace possible sur des données futures.



Interprétabilité et adaptation au contexte métier

Pourquoi Séparer à Nouveau les Données ?



Après avoir trouvé le modèle optimal, les meilleurs hyperparamètres et le seuil le plus efficace, j'ai séparé à nouveau les données. Cette dernière séparation permet d'entraîner le modèle final sur toutes les données disponibles tout en réservant une partie pour une validation finale. Cela garantit que le modèle est testé sur des données jamais vues, assurant ainsi une bonne généralisation.

Entraînement Final et Importance des Features :

Une fois les données bien séparées, j'ai ré-entraîné le modèle avec l'ensemble des données d'entraînement et les paramètres optimaux. Ensuite, j'ai évalué l'importance des différentes variables, car il est essentiel que le modèle soit non seulement performant, mais aussi compréhensible pour les utilisateurs finaux.


Interprétabilité et adaptation au contexte métier

LightGBM vs SHAP - Global importance




Interprétabilité et adaptation au contexte métier

Shap - Global importance



Interprétabilité et adaptation au contexte métier

Shap - Local importance





Interprétabilité et adaptation au contexte métier

Ajout

Pour améliorer l'interprétabilité et l'efficacité de mon modèle, j'ai d'abord évalué l'importance des différentes variables en utilisant deux méthodes : les importances des features de LightGBM et les valeurs SHAP. Ces deux approches m'ont permis de comprendre quelles variables avaient le plus d'impact sur les prédictions.

	Business Score	num_features	AUC	F1-Score	Precision	Recall
0	49057	20	0.759514	0.280923	0.181441	0.621912
1	47536	50	0.772893	0.291552	0.189459	0.632250
2	46270	75	0.779201	0.298920	0.194368	0.646885
3	46385	100	0.779561	0.298773	0.194523	0.643797
4	46020	150	0.781606	0.301421	0.196538	0.646348
5	45997	200	0.782375	0.301556	0.196628	0.646617
6	45470	250	0.783554	0.305019	0.199114	0.651584
7	45333	300	0.784834	0.305351	0.199110	0.654672
8	45509	350	0.785008	0.304561	0.198699	0.651853
9	45300	400	0.784656	0.305624	0.199330	0.654807



Conclusion et Perspectives

- **Modèle performant et interprétable :**
Le modèle final répond aux objectifs métier, offrant une prédiction efficace des risques de crédit tout en étant facile à comprendre pour les utilisateurs.
- **Optimisation des coûts métier :**
L'optimisation des hyperparamètres et la gestion des déséquilibres permettent de minimiser les erreurs coûteuses et d'améliorer les performances globales.
- **Impact pour "Prêt à Dépenser" :**
Ce modèle améliore la prise de décision en crédit, permettant une gestion des risques plus précise et des décisions éclairées.
- **Perspectives d'avenir :**
Améliorations potentielles via des données mises à jour régulièrement et des méthodes d'interprétabilité avancées.

Avez-vous des questions?

